

Instruções de Envio de Dados

CNN × São Leopoldo Mandic

Guia de Integração via Google Cloud Storage

Junho de 2026

1. Visão Geral

Este documento descreve o protocolo técnico para envio de dados da CNN para a plataforma de dados da São Leopoldo Mandic via Google Cloud Storage (GCS).

A CNN receberá acesso de escrita a um bucket GCS exclusivo provisionado na conta GCP da São Leopoldo Mandic. Os dados devem ser enviados seguindo o padrão de particionamento e estrutura definidos neste guia para garantir a ingestão automática no Data Lake.

2. Recursos Disponibilizados pela São Leopoldo Mandic

Recurso	Valor
Bucket GCS	a definir — exclusivo CNN (informado pela Mandic)
Projeto GCP	slmandic-datalake-hml
Conta de Serviço	Disponibilizada pela equipe de dados da Mandic (.json)
Permissões concedidas	storage.objects.create storage.objects.get (somente no bucket designado)

⚠ A conta de serviço possui permissão exclusivamente no bucket designado para a CNN. Qualquer tentativa de acesso a outros recursos será negada automaticamente pelo IAM.

3. Autenticação

A CNN deve utilizar a conta de serviço (arquivo .json) disponibilizada pela equipe da Mandic para autenticar no GCP. Três abordagens são suportadas:

3.1 Via variável de ambiente (recomendado para pipelines CI/CD)

```
export GOOGLE_APPLICATION_CREDENTIALS="/caminho/para/sua/service_account.json"
```

3.2 Via código Python — arquivo em disco

```
from google.cloud import storage
from google.oauth2 import service_account
```

```
credentials = service_account.Credentials.from_service_account_file(
    "/caminho/para/sua/service_account.json"
)
client = storage.Client(credentials=credentials)
```

3.3 Via código Python — JSON string em memória (Secret Manager)

```
import json, os
from google.cloud import storage
from google.oauth2 import service_account

info = json.loads(os.environ["GCP_SERVICE_ACCOUNT_JSON"])
credentials = service_account.Credentials.from_service_account_info(info)
client = storage.Client(credentials=credentials)
```

4. Estrutura de Arquivos no Bucket

4.1 Formato de arquivo

Todos os arquivos devem ser enviados no formato Parquet (.parquet).

- Parquet já aplica compressão interna — não é necessária compressão adicional.
- Encoding: UTF-8.
- Não utilizar CSV, JSON, Excel ou outros formatos.

4.2 Estrutura de diretórios — particionamento Hive-style

Os arquivos devem ser organizados em partições no estilo Hive, obedecendo à seguinte hierarquia de pastas dentro do bucket:

```
cnn/{nome_da_tabela}/partition_year={YYYY}/partition_month={MM}/partition_day={DD}/
```

Exemplos de caminhos completos:

```
cnn/audiencia_tv/partition_year=2026/partition_month=06/partition_day=16/data_batch_1_20260616_143022.parquet
cnn/programacao/partition_year=2026/partition_month=06/partition_day=16/data_batch_1_20260616_143500.parquet
```

Regras obrigatórias:

Chave de partição	Formato	Exemplo
partition_year	4 dígitos	2026
partition_month	2 dígitos (zero-padded)	06
partition_day	2 dígitos (zero-padded)	01

4.3 Nomenclatura dos arquivos

```
data_batch_{numero_do_lote}_{YYYYMMDD_HHMMSS}.parquet
```

Exemplos:

```
data_batch_1_20260616_143022.parquet
data_batch_2_20260616_143045.parquet
```

Para envio de arquivo único (não paginado):

data_20260616_143022.parquet

5. Coluna Obrigatória: ingestion_timestamp_raw

Todos os arquivos enviados devem conter a coluna **ingestion_timestamp_raw**. Esta coluna é utilizada internamente pela Mandic para rastreabilidade, auditoria e controle de qualidade da ingestão.

Campo	Especificação
Nome da coluna	ingestion_timestamp_raw
Tipo	datetime / TIMESTAMP
Fuso horário	UTC recomendado (ISO 8601)
Valor	Timestamp do momento em que o dado foi extraído/gerado na origem
Consistência	Mesmo valor para todos os registros de um mesmo arquivo/lote

Exemplo em Python:

```
import datetime
import pandas as pd

ingestion_timestamp_raw = datetime.datetime.utcnow()

# Adicionar a coluna ao DataFrame antes de salvar
df["ingestion_timestamp_raw"] = ingestion_timestamp_raw
```

⚠ A coluna **ingestion_timestamp_raw** deve refletir o momento da extração na origem, NÃO o momento do upload para o GCS.

6. Exemplo Completo de Envio em Python

Exemplo funcional que reúne todos os requisitos deste guia: autenticação via conta de serviço, particionamento Hive-style, adição da coluna **ingestion_timestamp_raw** e upload do arquivo Parquet para o bucket.

```
import datetime
import os
from tempfile import TemporaryDirectory

import pandas as pd
from google.cloud import storage
from google.oauth2 import service_account

# — Configurações —
BUCKET_NAME = "<nome-do-bucket-cnn>" # informado pela Mandic
TABLE_NAME = "audiencia_tv"
SERVICE_ACCOUNT_FILE = "/caminho/para/service_account.json"

# — Autenticação —
credentials =
service_account.Credentials.from_service_account_file(SERVICE_ACCOUNT_FILE)
client = storage.Client(credentials=credentials)
```

```

# — Dados —
df = pd.DataFrame({
    "programa": ["Jornal da CNN", "CNN Prime Time"],
    "audiencia": [1_200_000, 980_000],
    "data_exibicao": ["2026-06-16", "2026-06-16"],
})

# — Timestamp de ingestão (mesmo valor para todo o lote) —
ingestion_timestamp_raw = datetime.datetime.utcnow()
df["ingestion_timestamp_raw"] = ingestion_timestamp_raw

# — Particionamento —
now = datetime.datetime.utcnow()
hive_partition = (
    f"partition_year={now.year}/"
    f"partition_month={now.month:02d}/"
    f"partition_day={now.day:02d}"
)

# — Escrita e upload —
with TemporaryDirectory() as tmp:
    ts = now.strftime("%Y%m%d_%H%M%S")
    filename = f"data_batch_1_{ts}.parquet"
    local = f"{tmp}/{filename}"
    dest = f"cnn/{TABLE_NAME}/{hive_partition}/{filename}"

    df.to_parquet(local, index=False)

    bucket = client.get_bucket(BUCKET_NAME)
    blob = bucket.blob(dest)
    blob.upload_from_filename(local)

    print(f"Arquivo enviado: gs://{BUCKET_NAME}/{dest}")

```

7. Checklist de Validação Antes do Envio

Antes de cada envio, verifique os itens abaixo:

- ☐ O arquivo está no formato Parquet (.parquet)
- ☐ A estrutura de pastas segue o padrão
cnn/{tabela}/partition_year=.../partition_month=.../partition_day=.../
- ☐ A coluna ingestion_timestamp_raw está presente em todas as linhas
- ☐ O valor de ingestion_timestamp_raw é consistente dentro do mesmo lote
- ☐ O nome do arquivo segue o padrão data_batch_{n}_{timestamp}.parquet
- ☐ A autenticação foi feita com a conta de serviço disponibilizada pela Mandic

8. Bibliotecas Python Recomendadas

Biblioteca	Versão mínima	Uso
google-cloud-storage	>= 2.0.0	Upload de arquivos para o GCS

pandas	>= 1.5.0	Manipulação de DataFrames
pyarrow	>= 12.0.0	Serialização do formato Parquet

Instalação via pip:

```
pip install google-cloud-storage pandas pyarrow
```

9. Contato e Suporte

Em caso de dúvidas sobre configuração, credenciais ou estrutura de dados, entre em contato com a equipe de Dados da São Leopoldo Mandic:

Equipe	Data Platform — São Leopoldo Mandic
Responsável técnico	Pedro Mingueto
E-mail	fcamara_pedro.mingueto@slmandic.edu.br

10. Considerações de Segurança

- **Confidencialidade:** Não compartilhe o arquivo de conta de serviço (.json) em repositórios públicos ou sistemas não autorizados.
- **Armazenamento seguro:** Armazene as credenciais em variável de ambiente ou serviço de gerenciamento de segredos (ex: GCP Secret Manager).
- **Isolamento:** O acesso concedido é exclusivo ao bucket da CNN — tentativas de acesso a outros recursos serão bloqueadas automaticamente pelo IAM.
- **Rotação:** A rotação de credenciais será comunicada com antecedência pela equipe da Mandic.